Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное учреждение высшего образования
**«Национальный исследовательский университет ИТМО»**
Факультет программной инженерии и компьютерной техники

**ОТЧЁТ ПО ПРОЕКТУ**

# Распределённое обучение CatBoost с CTR и анализ задержки инференса

*Три майлстоуна по дисциплине «Распределённое машинное обучение»*

Выполнил: студент группы P4135
Баряев Андрей Алексеевич
Руководитель: доцент ФПИиКТ
Платонов Андрей Владимирович

Санкт-Петербург
2026

## АННОТАЦИЯ

В работе изучена связь распределённого обучения CatBoost с оптимизацией инференса моделей, содержащих категориальные статистики CTR. На небольшом Amazon выполнено обучение с одним, двумя и четырьмя отдельными Spark worker-процессами. На сохранённых 10 млн строк Criteo выполнено обучение модели с CTR на двух workers. Для моделей после обучения проверены совпадение предсказаний и квантили времени исходной и изменённой версии CatBoost. Во всех восьми ячейках с CTR p95 улучшился, а контроль без CTR не показал измеримого эффекта. Работники находились на одной физической машине; ускорение обучения большого CTR-набора при 1/2/4 workers не установлено.

## 1 БАЗОВАЯ ЛИНИЯ И ПОСТАНОВКА

Исходная НИР оптимизирует вычисление CTR во время CPU-предсказания. Эффект изменения кода оценивается на одной и той же модели и Pool; поэтому он не зависит от дополнительной настройки гиперпараметров при обучении. Базовая линия зафиксирована на Amazon, KDD и Criteo.

Таблица 1 – Модели базовой линии с CTR

| **Набор** | **CTR** | **Таблицы** | **Logloss** | **AUC** | **Изменение predict** |
|---|---|---|---|---|---|
| Amazon | 160 | 76 | 0,13577 | 0,88369 | -19,26% |
| KDD | 386 | 335 | 0,23351 | 0,75067 | -8,66% |
| Criteo sample | 355 | 296 | 0,13083 | 0,74501 | -4,56% |

Первый пробный распределённый запуск штатного CPU CLI CatBoost завершился на моделях без CTR. Для моделей с CTR он остановился с ошибкой TProjection. Поэтому следующий этап использует официальный CatBoost for Apache Spark 1.2.10; это отдельный механизм обучения с экспортом нативной модели для CPU-инференса.

## 2 РАСПРЕДЕЛЁННОЕ ОБУЧЕНИЕ С CTR

На Amazon обучено три модели: 24577 train-строк, 9 категориальных признаков, 20 деревьев глубины 4. У каждого запуска зафиксированы запрошенное и наблюдаемое число отдельных worker-процессов, модель, кодирование категорий и одинаковый holdout из 8192 строк. Каждая конфигурация запускалась один раз.

Таблица 2 – Результаты обучения Amazon с CTR

| **Workers** | **fit, c** | **CTR** | **Logloss** | **AUC** |
|---|---|---|---|---|
| 1 | 15,09 | 26 | 0,16003 | 0,85520 |
| 2 | 15,35 | 26 | 0,15798 | 0,85999 |
| 4 | 22,57 | 22 | 0,15846 | 0,85693 |




Рисунок 1 – Время обучения Amazon в зависимости от числа workers

На 24577 строках переход к четырём workers не ускорил обучение: 22,57 с против 15,09 с при одном. Это описание трёх отдельных запусков, а не точная оценка масштабирования. Число CTR также менялось: 26, 26 и 22; качество моделей близкое, но не совпадает.

На большом Criteo обучена отдельная модель на 10,000,000 строках с 2 workers: 13 числовых и 4 из 26 категориальных признаков, 10 CTR, fit 502.60

с. На 2 млн строк holdout: Logloss 0.491542, AUC 0.745674. Для этого большого CTR-набора нет запусков с одним и четырьмя workers, поэтому его масштабирование здесь не оценивается.

## 3 ИНФЕРЕНС И КВАНТИЛИ ЗАДЕРЖКИ

Пять моделей (Amazon CTR после 1/2/4 workers, Criteo CTR после 2 workers и контроль Amazon без CTR) измерены на готовом Pool. Два размера батча: 128 и 4096 строк; два потока; девять парных сессий на ячейку. Каждый вариант сделал 50 прогревочных и 1000 измеренных вызовов в новом процессе. Основная метрика - медиана парных изменений p95; интервал получен 20000 bootstrap-перерисовками целых парных сессий.

Таблица 3 – Парное изменение p95 предсказания

| **Модель** | **Батч 128** | **Батч 4096** |
|---|---|---|
| Amazon CTR, 1 worker | -24,11% [-30,01; -20,66] | -27,44% [-28,97; -22,90] |
| Amazon CTR, 2 workers | -20,77% [-26,78; -14,50] | -20,34% [-22,57; -19,03] |
| Amazon CTR, 4 workers | -20,55% [-22,53; -13,70] | -20,92% [-21,75; -18,12] |
| Criteo CTR, 2 workers | -12,86% [-19,73; -4,69] | -17,64% [-18,23; -14,50] |
| Amazon без CTR, 2 workers | -0,09% [-2,28; +5,08] | +0,52% [-2,18; +3,75] |

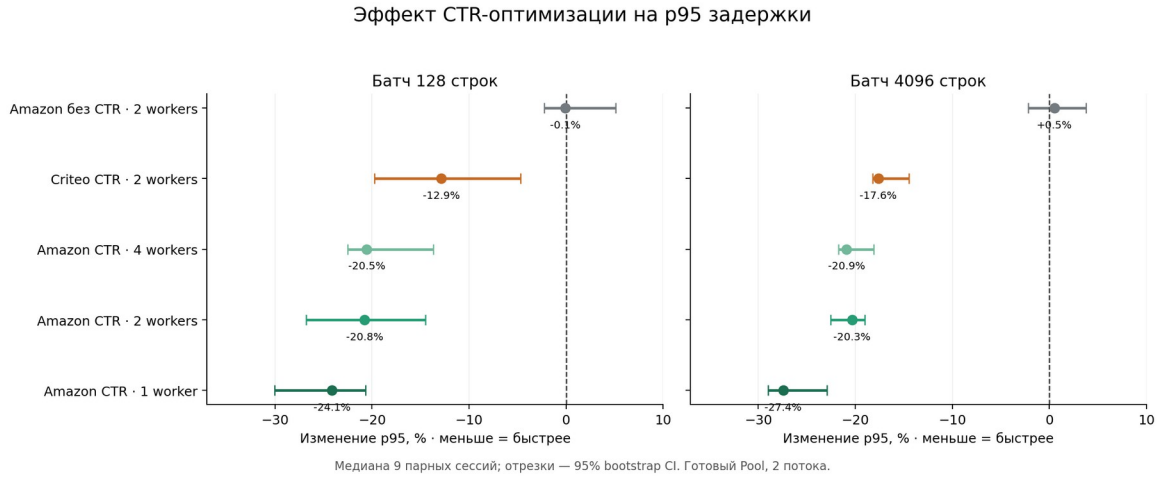



Рисунок 2 – Эффект оптимизации на p95 задержки

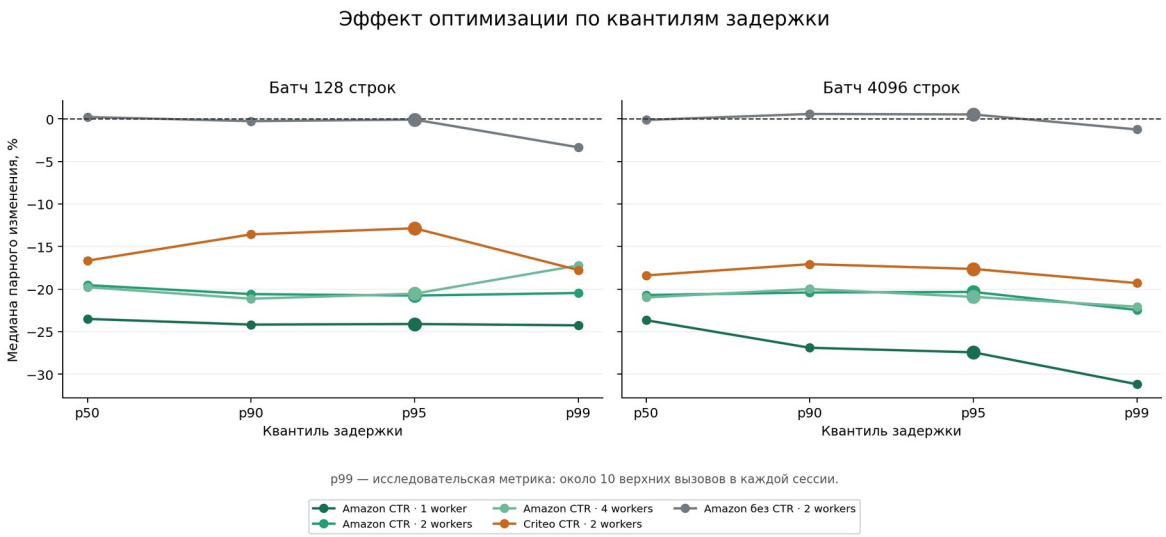



Рисунок 3 – Изменение p50, p90, p95 и p99

Во всех восьми CTR-ячейках p95 ниже исходного: 9 из 9 парных сессий быстрее, интервалы не включают ноль. В двух ячейках контроля без CTR интервалы включают ноль. Исходная и изменённая версии дали побитово одинаковые предсказания на полных holdout: 8192 строк Amazon и 2 млн строк Criteo. p99 остаётся исследовательской метрикой: верхний один процент содержит примерно десять вызовов за сессию. Интервалы не скорректированы на множественные сравнения.

## 4 ОГРАНИЧЕНИЯ И ВЫВОДЫ

Рабочие процессы Spark находились на одном физическом компьютере. Время обучения Criteo с CTR получено только для двух workers. Amazon слишком мал для вывода о масштабировании большого CTR-набора. Модели после обучения имеют разную структуру, поэтому различие процентов инференса не следует приписывать одному числу workers.

Измеренный p95 относится к многократным вызовам CPU predict на готовом Pool; он не равен p95 сетевого сервиса с очередями и новой загрузкой модели. Измерительные бинарники содержат две основные CTR-оптимизации, но не более позднюю FIFO-политику вытеснения из TLS-кеша. Для неё отдельной оценки задержки нет.

Итог: распределённое обучение CatBoost с CTR технически проверено на 1/2/4 отдельных процессах, а также на крупном наборе с двумя процессами. Для полученных моделей показано сохранение предсказаний и снижение p95 в CTR-сценариях. Следующий шаг - оценка обучения большого CTR-набора с 1/4 workers и, при необходимости, на разных физических машинах.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. CatBoost Documentation. CatBoost for Apache Spark. URL: https://catboost.ai/docs/en/concepts/spark-overview.

2. CatBoost source repository. URL: https://github.com/catboost/catboost.

3. Протокол и артефакты эксперимента: results/stage3/distributed_ctr_quantiles_20261107/.

4. Артефакты обучения: results/stage2/amazon_ctr_spark_mapped_20261107/ и results/stage2/criteo_x1_ctr_spark2_20261107/.