Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

ОТЧЁТ ПО МАЙЛСТОУНУ 1

Базовая линия CatBoost с CTR и пробный распределённый запуск

Качество, CTR-структура, время обучения и инференса на одной машине

Дисциплина «Распределённое машинное обучение»

Выполнил: студент группы P4235
Баряев Андрей Алексеевич

Проверил: Платонов Алексей Владимирович

Санкт-Петербург
2026

1. Цель майлстоуна

Зафиксировать на одной машине качество моделей, CTR-структуру, время обучения и время предсказания для наборов Amazon, KDD и Criteo; проверить запуск CatBoost с двумя worker-процессами; сравнить исходный CatBoost с CTR-оптимизацией на одной модели и проверить совпадение предсказаний.

2. Выполнение требований плана

Требование плана	Статус	Где результат
Качество, CTR-структура, время обучения и предсказаний для Amazon, KDD, Criteo	выполнено	results/stage1/records.json, structure.json, predict_singlehost/records.json
Пробный запуск с двумя worker-процессами	выполнено частично: без CTR успешно, с CTR падает	results/stage2_stock/records.json, поле failure_tail (разделы 3–4)
Сравнение исходного и CTR-оптимизированного CatBoost на одной модели	выполнено	predict_singlehost/records.json, 18 записей
Совпадение предсказаний исходной и оптимизированной версии	выполнено	поле equality = true во всех 18 записях

3. Базовая линия: модели и метрики

Все модели обучены штатным CPU CLI CatBoost 1.2.10 с 200 итерациями; holdout совпадает с выборкой этапа 1 (данные и SHA-256 в data/manifest.json). Время predict измерено на готовом Pool, батч 4096, два потока, девять парных сессий, 200 повторов на сессию. Исходный и оптимизированный CatBoost дали одинаковые предсказания во всех сессиях (equality = true).

Таблица 1 — Базовая линия (CPU, одна машина)

Набор и модель	Train / holdout	CTR признаков / таблиц	fit, с	Logloss	AUC	predict, мс: исх. / опт.	Изменение predict
Amazon, CTR	24 577 / 8 192	160 / 76	1,71	0,13577	0,88369	2,609 / 2,099	−19,26%
KDD, CTR	37 500 / 12 500	386 / 335	6,18	0,23351	0,75067	5,880 / 5,352	−8,66%
Criteo, CTR	1 557 838 / 757 695	355 / 296	186,28	0,13083	0,74501	8,743 / 8,152	−4,56%
Amazon, без CTR	24 577 / 8 192	0 / 0	0,91	0,17712	0,80990	1,083 / 1,090	+0,37%
KDD, без CTR	37 500 / 12 500	0 / 0	0,80	0,24134	0,72381	0,769 / 0,775	+0,70%
Criteo, без CTR	1 557 838 / 757 695	0 / 0	5,94	0,13600	0,70146	0,685 / 0,684	−0,13%

Примечание. fit — штатный CLI этапа 1 (8 потоков). predict — два потока, батч 4096, девять парных сессий по 200 повторов; изменение — медиана парных изменений медианы времени на сессию. Для строк без CTR predict измерен на модели, обученной одиночным хостом с 3 потоками (single3).

3.1. CTR-структура базовых моделей

Таблица 2 — Структура CTR базовых моделей (structure.py)

Модель	CTR признаков	CTR таблиц	проекций	CTR на таблицу	доля соседних пар одной таблицы	деревьев
Amazon	160	76	55	2,11	0,53	200
KDD	386	335	144	1,15	0,13	200
Criteo	355	296	121	1,20	0,17	200

Модели этапа 1 обучены на 200 деревьях. Это другие модели, чем распределённые модели майлстоунов 2 и 3 (20 деревьев глубины 4); поэтому их predict-результаты не объединяются с майлстоуном 3.

4. Пробный распределённый запуск (штатный CatBoost, 2 worker-процесса)

Запуск выполнен штатным протоколом CatBoost: отдельный процесс run-worker на каждого worker, один master, hosts-файл, все процессы на 127.0.0.1. Каждый worker использовал 3 потока.

Таблица 3 — Штатный распределённый запуск с 2 worker-процессами

Набор	Результат	fit, с	Logloss	AUC
amazon_onehot	успешно	16,15	0,17864	0,80479
kdd_num	успешно	12,20	0,24107	0,72435
criteo_num	успешно	16,56	0,13604	0,70112
amazon_ctr	ошибка, exit -6	—	—	—
kdd_ctr	ошибка, exit -6	—	—	—
criteo_ctr	ошибка, exit -6	—	—	—

Модели без CTR (one-hot Amazon, числовой KDD и Criteo) обучаются штатным режимом без ошибок. Модели с CTR во всех трёх наборах завершаются аварийно (exit −6, SIGABRT) с сообщением «Key not found in hashtable: TProjection» в worker-логах. Ошибка воспроизведена в повторном запуске (amazon_ctr_dist2_failure_clean, status: rc=134). Фрагменты логов сохранены в results/stage2_stock/records.json (поле failure_tail); полные логи в репозиторий не включены. Поэтому для CTR-моделей майлстоуны 2 и 3 используют официальный CatBoost for Apache Spark 1.2.10.

5. Демонстрация

- Показать таблицы 1–3 и открыть results/stage1/records.json (поля quality, structure, fit_wall_s).
- Показать строку equality = true в results/stage1/predict_singlehost/records.json.
- Показать поле failure_tail с «TProjection» в results/stage2_stock/records.json (amazon_ctr_dist2_failure).

6. Критерий завершения и ограничения

Майлстоун выполнен: воспроизводимая базовая линия с качеством, CTR-структурой и временем работы; пробный запуск с двумя worker-процессами работает для моделей без CTR, для моделей с CTR зафиксирована воспроизводимая ошибка штатного режима.

- Каждая модель обучена один раз; для M1 разброс обучения не измерялся.
- Время fit для Criteo (186 с) получено на одной машине без контроля фоновой нагрузки.
- Измерения predict — повторные вызовы в одном процессе, а не задержка сетевого сервиса.