Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

ОТЧЁТ ПО МАЙЛСТОУНУ 2

Распределённое обучение CatBoost с CTR

Сравнение 1, 2 и 4 worker-процессов по времени, качеству и накладным расходам

Дисциплина «Распределённое машинное обучение»

Выполнил: студент группы P4135
Баряев Андрей Алексеевич

Руководитель: доцент ФПИиКТ
Платонов Андрей Владимирович

Санкт-Петербург
2026

1. Цель майлстоуна

Сравнить обучение с 1, 2 и 4 worker-процессами по времени, качеству модели и накладным расходам, используя штатный распределённый режим CatBoost. Все worker-процессы работают на одной физической машине.

2. Выполнение требований плана

Требование плана	Статус	Где результат
Сравнение 1, 2, 4 worker-ов по времени и качеству (штатный режим)	выполнено для моделей без CTR; один запуск на конфигурацию	results/stage2_stock/summary.tsv
Накладные расходы распределения	выполнено частично: старт процесса, разница с одиночным хостом; Spark-старт не измерен	раздел 3.2
Обучение с CTR при 1, 2, 4 worker-ах	не выполнено штатным режимом (ошибка TProjection); выполнено на Spark для Amazon (1/2/4) и Criteo (2)	раздел 4
Три независимых seed для основных сравнений	не выполнено; одна конфигурация — один запуск	раздел 6

3. Штатный распределённый режим CatBoost (модели без CTR)

Три набора: Amazon one-hot (24 577 строк, 9 категориальных), KDD числовой (37 500 строк, 190 числовых), Criteo числовой (1 557 838 строк, 13 числовых). Во всех запусках 200 итераций, 3 потока на worker, одинаковое разбиение holdout. Строки single — одиночный хост, 3 и 12 потоков.

Таблица 4 — Штатный распределённый режим и одиночный хост, модели без CTR

Запуск	Workers	Потоков всего	fit, с	старт, с	Logloss	AUC	fit / лучший одиночный
amazon_onehot_single3	—	3	0,98	—	0,17712	0,8099	1,00
amazon_onehot_single12	—	12	1,02	—	0,17712	0,8099	1,04
amazon_onehot_dist1	1	3	8,13	0,104	0,17834	0,8011	8,27
amazon_onehot_dist2	2	6	16,15	0,108	0,17864	0,8048	16,45
amazon_onehot_dist4	4	12	20,16	0,110	0,17783	0,8053	20,53
kdd_num_single3	—	3	1,25	—	0,24134	0,7238	1,55
kdd_num_single12	—	12	0,81	—	0,24134	0,7238	1,00
kdd_num_dist1	1	3	8,19	0,107	0,24142	0,7223	10,11
kdd_num_dist2	2	6	12,20	0,107	0,24107	0,7243	15,06
kdd_num_dist4	4	12	18,21	0,111	0,24072	0,7258	22,48
criteo_num_single3	—	3	12,70	—	0,13600	0,7015	2,12
criteo_num_single12	—	12	5,98	—	0,13600	0,7015	1,00
criteo_num_dist1	1	3	20,56	0,107	0,13601	0,7013	3,44
criteo_num_dist2	2	6	16,56	0,108	0,13604	0,7011	2,77
criteo_num_dist4	4	12	14,55	0,108	0,13603	0,7011	2,43

Примечание. «fit / лучший одиночный» — отношение времени fit к самому быстрому одиночному запуску того же набора (1,0 — лучший). Полная таблица с ошибками: results/stage2_stock/summary.tsv.

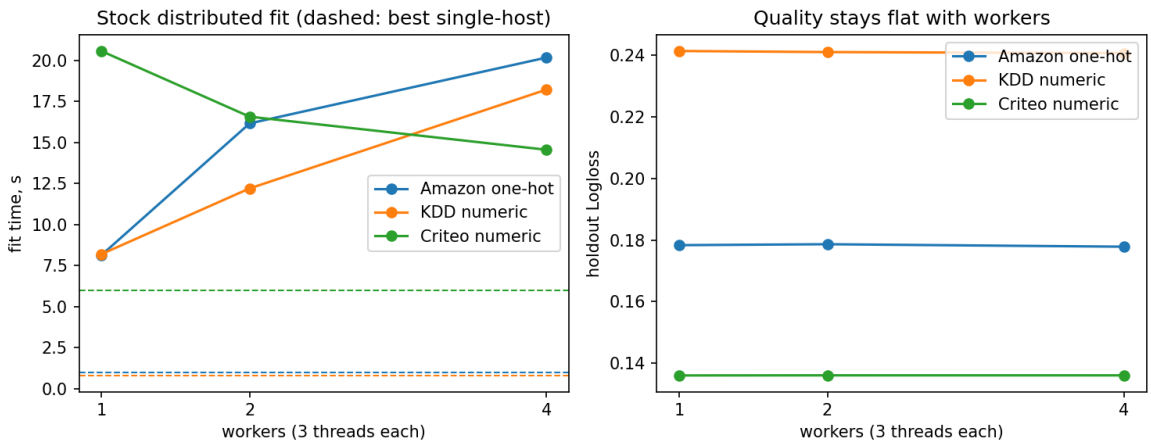


Рисунок 1 — Время обучения (слева) и Logloss (справа) штатного режима; пунктир — лучший одиночный хост

3.1. Что показывают измерения

- Качество не зависит от числа worker-ов в пределах шума: Logloss Amazon 0,1778–0,1786, KDD 0,2407–0,2414, Criteo 0,13600–0,13604.
- Время растёт с числом worker-ов на Amazon (8,1 → 16,2 → 20,2 с) и KDD (8,2 → 12,2 → 18,2 с).
- Criteo ускоряется от 20,6 с (1 worker) до 14,6 с (4 worker-а): коэффициент 1,41 при четырёх процессах.
- Ни один распределённый запуск не быстрее одиночного хоста с 12 потоками; лучший распределённый результат на Criteo (14,6 с) в 2,4 раза медленнее одиночного запуска (6,0 с).

3.2. Накладные расходы

Старт worker-процесса и подключение к master занимают 0,10–0,11 с (поле startup_s). Разница между полным временем процесса и fit составляет 0,11–1,96 с. Основной оверхед возникает внутри обучения: на каждой итерации worker-ы обмениваются статистиками с master. Например, Amazon при одном worker-е с тремя потоками обучается 8,1 с против 1,0 с одиночного хоста с тремя потоками.

4. Обучение с CTR: официальный CatBoost for Apache Spark

Штатный режим с CTR не работает (майлстоун 1). Поэтому для CTR-моделей использован официальный CatBoost for Apache Spark 1.2.10 в режиме local-cluster: отдельные JVM-процессы на одной машине. Все конфигурации: 20 деревьев глубины 4, одинаковое кодирование категорий и holdout.

Таблица 5 — Обучение с CTR на CatBoost Spark

Конфигурация	Executors	fit, с	CTR признаков	Logloss	AUC
Amazon CTR, 1 worker	1	15,09	26	0,16003	0,85520
Amazon CTR, 2 worker	2	15,35	26	0,15798	0,85999
Amazon CTR, 4 worker	4	22,57	22	0,15846	0,85693
Criteo CTR (10 млн строк), 2 worker	2	502,60	10	0,49154	0,74567



Рисунок 2 — Время обучения Amazon CTR при 1, 2 и 4 worker-ах (Spark)

На Amazon (24 577 строк) с 4 worker-ами обучение медленнее (22,6 с против 15,1 с при одном). Число CTR-признаков меняется (26, 26, 22), поэтому модели не идентичны. Criteo запущен только с 2 worker-ами: масштабирование большого CTR-набора не измерено.

5. Демонстрация

- Показать таблицу 4 и рисунок 1: одиночный хост быстрее всех распределённых запусков.
- Показать команду python3 scripts/summarize_stock_distributed.py и summary.tsv.
- Показать запись amazon_onehot_dist2 в results/stage2_stock/records.json (время, старт, метрики).

6. Ограничения и статус

- Одна конфигурация — один запуск. Общее правило проекта требует три независимых seed для основных сравнений; этого не сделано. Разброс времени и качества между запусками не оценён.

- Число потоков растёт вместе с числом worker-ов (3 потока на worker). Сравнение с одиночным хостом не является сравнением при равном бюджете потоков.
- Все worker-процессы на одной машине; распределение по физическим машинам не выполнялось.
- Оценка масштабирования CTR на Criteo при 1 и 4 worker-ах не выполнена.

Статус: майлстоун выполнен частично. Штатный режим измерен на моделях без CTR; CTR-модели обучены на Spark; вопрос о пользе распределения для CTR-обучения на крупном наборе остаётся открытым.