Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

# ОТЧЁТ ПО МАЙЛСТОУНУ 2

## Распределённое обучение CatBoost с CTR

Сравнение 1, 2 и 4 worker-процессов по времени, качеству и накладным расходам

Дисциплина «Распределённое машинное обучение»

Выполнил: студент группы P4235
Баряев Андрей Алексеевич

Проверил: Платонов Алексей Владимирович

Санкт-Петербург
2026

## 1. Цель майлстоуна

Сравнить обучение с 1, 2 и 4 worker-процессами по времени, качеству модели и накладным расходам, используя штатный распределённый режим CatBoost. Все worker-процессы работают на одной физической машине.

## 2. Выполнение требований плана

| Требование плана | Статус | Где результат |
|---|---|---|
| Сравнение 1, 2, 4 worker-ов по времени и качеству (штатный режим) | выполнено для моделей без CTR; один запуск на конфигурацию | results/stage2_stock/summary.tsv |
| Накладные расходы распределения | выполнено частично: старт процесса, разница с одиночным хостом; Spark-старт не измерен | раздел 3.2 |
| Обучение с CTR при 1, 2, 4 worker-ах | не выполнено штатным режимом (ошибка TProjection); выполнено на Spark для Amazon (1/2/4) и Criteo (2) | раздел 4 |
| Три независимых seed для основных сравнений | не выполнено; одна конфигурация — один запуск | раздел 6 |

## 3. Штатный распределённый режим CatBoost (модели без CTR)

Три набора: Amazon one-hot (24 577 строк, 9 категориальных), KDD числовой (37 500 строк, 190 числовых), Criteo числовой (1 557 838 строк, 13 числовых). Во всех запусках 200 итераций, 3 потока на worker, одинаковое разбиение holdout. Строки single — одиночный хост, 3 и 12 потоков.

**Таблица 4 — Штатный распределённый режим и одиночный хост, модели без CTR**

| Запуск | Workers | Потоков всего | fit, с | старт, с | Logloss | AUC | fit / лучший одиночный |
|---|---|---|---|---|---|---|---|
| Amazon S3 | — | 3 | 0,98 | — | 0,17712 | 0,8099 | 1,00 |
| Amazon S12 | — | 12 | 1,02 | — | 0,17712 | 0,8099 | 1,04 |
| Amazon W1 | 1 | 3 | 8,13 | 0,104 | 0,17834 | 0,8011 | 8,27 |
| Amazon W2 | 2 | 6 | 16,15 | 0,108 | 0,17864 | 0,8048 | 16,45 |
| Amazon W4 | 4 | 12 | 20,16 | 0,110 | 0,17783 | 0,8053 | 20,53 |
| KDD S3 | — | 3 | 1,25 | — | 0,24134 | 0,7238 | 1,55 |
| KDD S12 | — | 12 | 0,81 | — | 0,24134 | 0,7238 | 1,00 |
| KDD W1 | 1 | 3 | 8,19 | 0,107 | 0,24142 | 0,7223 | 10,11 |
| KDD W2 | 2 | 6 | 12,20 | 0,107 | 0,24107 | 0,7243 | 15,06 |
| KDD W4 | 4 | 12 | 18,21 | 0,111 | 0,24072 | 0,7258 | 22,48 |
| Criteo S3 | — | 3 | 12,70 | — | 0,13600 | 0,7015 | 2,12 |
| Criteo S12 | — | 12 | 5,98 | — | 0,13600 | 0,7015 | 1,00 |
| Criteo W1 | 1 | 3 | 20,56 | 0,107 | 0,13601 | 0,7013 | 3,44 |
| Criteo W2 | 2 | 6 | 16,56 | 0,108 | 0,13604 | 0,7011 | 2,77 |
| Criteo W4 | 4 | 12 | 14,55 | 0,108 | 0,13603 | 0,7011 | 2,43 |

*Примечание. S3/S12 — одиночный хост с 3/12 потоками; W1/W2/W4 — распределённый режим с 1/2/4 worker-процессами по 3 потока. Например, Amazon W2 соответствует amazon_onehot_dist2 в summary.tsv. «fit / лучший одиночный» — отношение времени fit к самому быстрому одиночному запуску того же набора (1,0 — лучший). Полная таблица: results/stage2_stock/summary.tsv.*

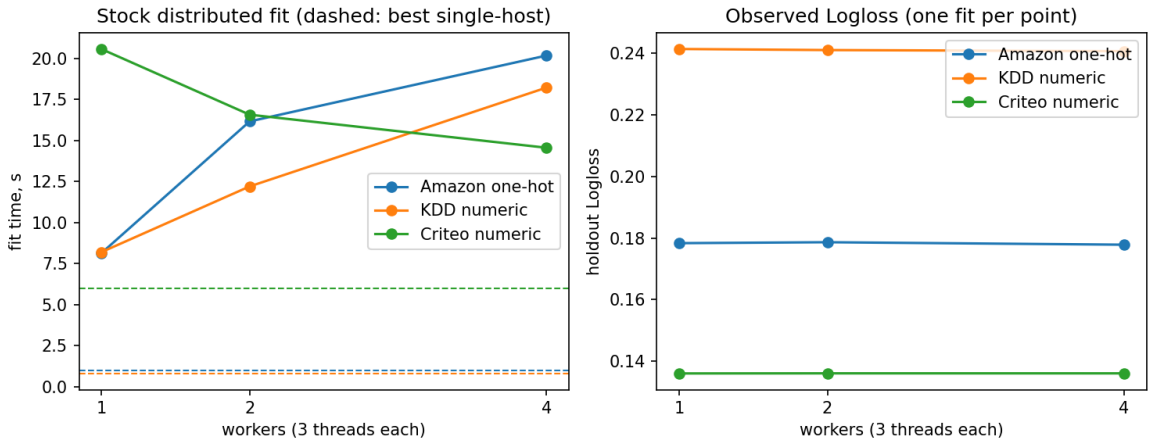



*Рисунок 1 — Время обучения (слева) и Logloss (справа) штатного режима; пунктир — лучший одиночный хост*

### 3.1. Что показывают измерения

- В одиночных запусках значения Logloss близки: Amazon 0,1778–0,1786, KDD 0,2407–0,2414, Criteo 0,13600–0,13604. Каждая конфигурация обучалась один раз, поэтому разброс между запусками и влияние числа worker-ов на качество статистически не оценены.
- Время растёт с числом worker-ов на Amazon (8,1 → 16,2 → 20,2 с) и KDD (8,2 → 12,2 → 18,2 с).
- Criteo ускоряется от 20,6 с (1 worker) до 14,6 с (4 worker-а): коэффициент 1,41 при четырёх процессах.
- Ни один распределённый запуск не быстрее одиночного хоста с 12 потоками; лучший распределённый результат на Criteo (14,6 с) в 2,4 раза медленнее одиночного запуска (6,0 с).

### 3.2. Накладные расходы

От запуска worker-процессов до открытия их портов проходит 0,10–0,11 с (поле startup_s). Master в этот момент ещё не запущен, поэтому подключение к нему эта метрика не измеряет. Разница между полным временем процесса и fit составляет 0,11–1,96 с. Сравнение Amazon при трёх потоках показывает 8,1 с для одного worker-а против 1,0 с на одиночном хосте. Разница приходится главным образом на fit; вклад сетевого обмена отдельно от других затрат распределённого режима не измерялся.

## 4. Обучение с CTR: официальный CatBoost for Apache Spark

Штатный режим с CTR не работает (майлстоун 1). Поэтому для CTR-моделей использован официальный CatBoost for Apache Spark 1.2.10 в режиме local-cluster: отдельные JVM-процессы на одной машине. Все конфигурации: 20 деревьев глубины 4, одинаковое кодирование категорий и holdout.

**Таблица 5 — Обучение с CTR на CatBoost Spark**

| Конфигурация | Executors | fit, с | CTR признаков | Logloss | AUC |
|---|---|---|---|---|---|
| Amazon CTR, 1 worker | 1 | 15,09 | 26 | 0,16003 | 0,85520 |
| Amazon CTR, 2 worker | 2 | 15,35 | 26 | 0,15798 | 0,85999 |
| Amazon CTR, 4 worker | 4 | 22,57 | 22 | 0,15846 | 0,85693 |
| Criteo CTR (10 млн строк), 2 worker | 2 | 502,60 | 10 | 0,49154 | 0,74567 |




*Рисунок 2 — Время обучения Amazon CTR при 1, 2 и 4 worker-ах (Spark)*

На Amazon (24 577 строк) с 4 worker-ами обучение медленнее (22,6 с против 15,1 с при одном). Число CTR-признаков меняется (26, 26, 22), поэтому модели не идентичны. Criteo запущен только с 2 worker-ами: масштабирование большого CTR-набора не измерено.

## 5. Демонстрация

- Показать таблицу 4 и рисунок 1: одиночный хост быстрее всех распределённых запусков.
- Показать команду python3 scripts/summarize_stock_distributed.py и summary.tsv.
- Показать запись amazon_onehot_dist2 в results/stage2_stock/records.json (время, старт, метрики).

## 6. Ограничения и статус

- Одна конфигурация — один запуск. Общее правило проекта требует три независимых seed для основных сравнений; этого не сделано. Разброс времени и качества между запусками не оценён.
- Число потоков растёт вместе с числом worker-ов (3 потока на worker). Сравнение с одиночным хостом не является сравнением при равном бюджете потоков.
- Все worker-процессы на одной машине; распределение по физическим машинам не выполнялось.
- Оценка масштабирования CTR на Criteo при 1 и 4 worker-ах не выполнена.

Статус: майлстоун выполнен частично. Штатный режим измерен на моделях без CTR; CTR-модели обучены на Spark; вопрос о пользе распределения для CTR-обучения на крупном наборе остаётся открытым.