Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет программной инженерии и компьютерной техники

ОТЧЁТ ПО МАЙЛСТОУНУ 3

Инференс моделей распределённого обучения

CTR-структура моделей и сравнение исходного и оптимизированного predict

Дисциплина «Распределённое машинное обучение»

Выполнил: студент группы P4235
Баряев Андрей Алексеевич

Проверил: Платонов Алексей Владимирович

Санкт-Петербург
2026

1. Цель майлстоуна

Взять модели, обученные с разным числом worker-процессов, изучить сформированные в них CTR-признаки; на одном и том же тестовом наборе сравнить время предсказания исходного CatBoost и версии с CTR-оптимизацией, проверить совпадение предсказаний и оценить, зависит ли эффект от структуры CTR.

Распределённым является только обучение моделей. Измеряемое предсказание (predict) выполняется локально одним процессом на CPU с двумя потоками; worker-процессы в инференсе не участвуют.

2. Выполнение требований плана

Требование плана	Статус	Где результат
Изучение CTR-признаков моделей с разным числом worker-ов	выполнено	таблица 6, results/stage3/ctr_structure/
Сравнение времени predict исходного и оптимизированного CatBoost на одном тестовом наборе	выполнено (9 парных сессий, батчи 128 и 4096)	таблица 7, results/stage3/distributed_ctr_quantiles_20261107/
Проверка совпадения предсказаний	выполнено на полном holdout всех пяти моделей	таблица 8, equivalence.json
Оценка зависимости эффекта от структуры CTR	выполнено описательно; статистической зависимости не установлено (4 модели с CTR)	раздел 5

3. CTR-структура распределённых моделей

Структура получена скриптом structure.py из нативных моделей CatBoost (.cbm), обученных в майлстоуне 2. SHA-256 моделей записан в results/stage3/ctr_structure/structure.json.

Таблица 6 — CTR-структура пяти моделей

Модель	CTR признаков	CTR таблиц	проекций	CTR на таблицу	доля соседних пар одной таблицы	кат. / числ. признаков	деревьев
amazon_ctr_1w	26	11	9	2,36	0,60	9 / 0	20
amazon_ctr_2w	26	14	9	1,86	0,48	9 / 0	20
amazon_ctr_4w	22	11	9	2,00	0,52	9 / 0	20
criteo_ctr_2w	10	4	3	2,50	0,67	4 / 13	20
amazon_noctr_2w	0	0	0	0,00	0,00	9 / 0	200

Все CTR-признаки имеют сложность 1 (одна категориальная комбинация). Типы CTR: в основном Borders, небольшое число Counter. Модель amazon_noctr_2w — контроль без CTR; у неё 200 деревьев против 20 у остальных, поэтому контроль отличается не только отсутствием CTR.

4. Протокол и результаты измерений

Протокол зафиксирован до измерений (results/stage3/distributed_ctr_quantiles_20261107/protocol.txt). Предиктор — два зафиксированных бинарника харнесса CatBoost v1.2.10: исходный (stock) и оптимизированный (production, с переиспользованием бакетов и кешем группировки; FIFO-вытеснение в них не входит). Нагрузка: predict на готовом Pool, два потока, 50 прогревов и 1000 измеренных вызовов в каждом процессе, девять парных сессий на ячейку. Основная метрика — медиана парных изменений p95. Интервалы получены bootstrap по парным сессиям (20 000 повторов, seed 20261107).

Таблица 7 — Парное изменение p95 predict (отрицательное — оптимизированная версия быстрее)

Модель	Батч	p95: медиана изменения	95% интервал	сессий быстрее
amazon_ctr_1w	128	−24,11%	[−30,01; −20,66]	9/9
amazon_ctr_1w	4096	−27,44%	[−28,97; −22,90]	9/9
amazon_ctr_2w	128	−20,77%	[−26,78; −14,50]	9/9
amazon_ctr_2w	4096	−20,34%	[−22,57; −19,03]	9/9
amazon_ctr_4w	128	−20,55%	[−22,53; −13,70]	9/9
amazon_ctr_4w	4096	−20,92%	[−21,75; −18,12]	9/9
criteo_ctr_2w	128	−12,86%	[−19,73; −4,69]	9/9
criteo_ctr_2w	4096	−17,64%	[−18,23; −14,50]	9/9
amazon_noctr_2w	128	−0,09%	[−2,28; +5,08]	5/9
amazon_noctr_2w	4096	+0,52%	[−2,18; +3,75]	4/9

Таблица 8 — Квантили задержки (медиана парных изменений, все ячейки)

Модель	Батч	p50	p90	p95	p99	p99: интервал без нуля
amazon_ctr_1w	128	−23,51%	−24,18%	−24,11%	−24,26%	нет
amazon_ctr_1w	4096	−23,66%	−26,90%	−27,44%	−31,19%	да
amazon_ctr_2w	128	−19,54%	−20,59%	−20,77%	−20,47%	да
amazon_ctr_2w	4096	−20,70%	−20,41%	−20,34%	−22,46%	да
amazon_ctr_4w	128	−19,78%	−21,14%	−20,55%	−17,23%	да
amazon_ctr_4w	4096	−20,99%	−19,99%	−20,92%	−22,07%	да
criteo_ctr_2w	128	−16,67%	−13,57%	−12,86%	−17,76%	да
criteo_ctr_2w	4096	−18,40%	−17,07%	−17,64%	−19,30%	да
amazon_noctr_2w	128	+0,21%	−0,27%	−0,09%	−3,34%	нет
amazon_noctr_2w	4096	−0,13%	+0,58%	+0,52%	−1,25%	нет

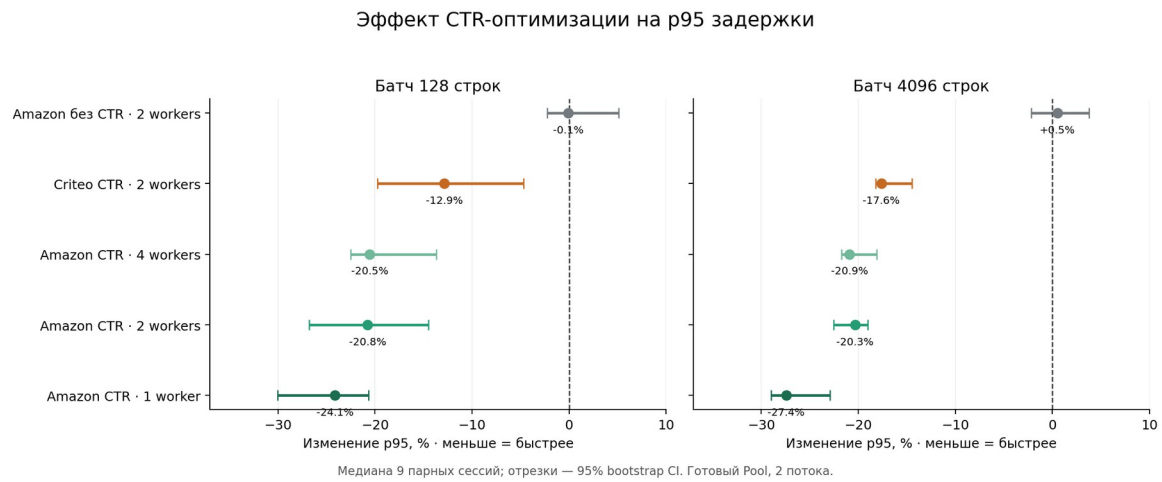


Рисунок 3 — Парное изменение p95 по моделям и батчам

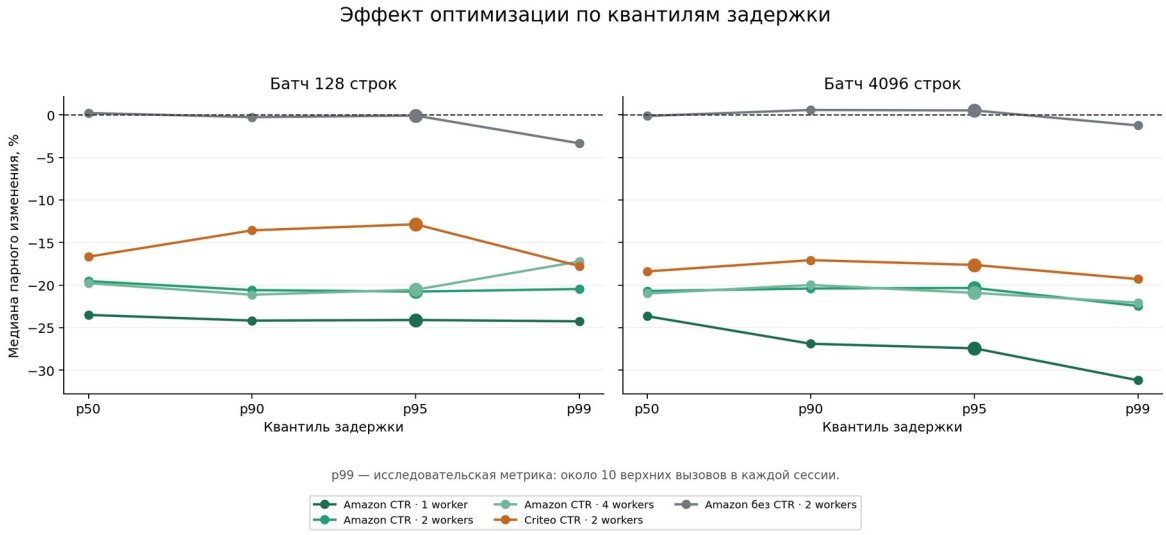


Рисунок 4 — Изменение p50, p90, p95, p99

4.1. Совпадение предсказаний

Таблица 9 — Проверка совпадения предсказаний

Модель	строк holdout	побитовое совпадение (хеши полного вектора и блоков)
amazon_ctr_1w	8 192	совпадают
amazon_ctr_2w	8 192	совпадают
amazon_ctr_4w	8 192	совпадают
criteo_ctr_2w	2 000 000	совпадают
amazon_noctr_2w	8 192	совпадают

5. Зависит ли эффект от структуры CTR

Для трёх моделей Amazon с CTR (1, 2 и 4 worker-а) число CTR-таблиц равно 11, 14 и 11; эффект при батче 4096 составляет −27,44%, −20,34% и −20,92%. При батче 4096 наибольший эффект у модели с 1 worker-ом, хотя число таблиц у неё совпадает с 4 worker-ами. Структурные показатели (таблицы, доля соседних пар одной таблицы) не объясняют различие.

Модель Criteo (10 CTR-признаков, 4 таблицы, 13 числовых признаков) даёт эффект −12,86% при батче 128 и −17,64% при батче 4096. Она отличается от моделей Amazon и по набору признаков, и по структуре CTR, поэтому её величину нельзя приписать одной структурной характеристике. Доля CTR-вычислений во времени предсказания в этих измерениях не выделялась. С четырьмя CTR-моделями статистическую зависимость от структуры установить нельзя. Вывод ограничен: CTR-оптимизация даёт выигрыш на всех четырёх CTR-моделях, а его величина различается.

6. Демонстрация

- Показать таблицу 6 и рисунок 3; объяснить, что такое парная сессия и 9/9.
- Показать таблицу 9: предсказания исходной и оптимизированной версии побитово совпадают.
- Команда пересчёта без моделей: python3 scripts/run_distributed_ctr_quantiles.py --summarize-only.

7. Ограничения и статус

- p95 относится к повторным вызовам predict в одном процессе, а не к задержке сетевого сервиса.
- Производственная версия не содержит отдельного изменения FIFO-вытеснения кеша; его эффект не измерен.
- p99 — исследовательская метрика: верхний один процент содержит около десяти вызовов в сессии. Интервалы не скорректированы на множественные сравнения.
- Модели с CTR различаются по числу деревьев от контроля (20 против 200), контроль не полностью совпадает по структуре.

Статус: майлстоун выполнен. Сравнение и квантили выполнены для всех заранее объявленных ячеек, предсказания совпадают на полном holdout.